

Assistente clínico institucional

Relatório técnico

Protótipo local com dados sintéticos, ajuste fino de LLM, recuperação documental e fluxo de segurança.

1. Finalidade

O protótipo organiza informações clínicas sintéticas para revisão profissional. Ele foi estruturado para mostrar como um modelo de linguagem pode ser ajustado e inserido em um fluxo controlado, sem assumir decisões médicas. A aplicação não altera registros, não prescreve e não emite comunicações externas.

O processamento separa tarefas que têm responsabilidades diferentes. A base estruturada fornece dados do paciente; a recuperação encontra protocolos relacionados; o modelo gera um rascunho a partir desse contexto; e o grafo controla quais situações podem chegar à geração e quais devem ser interrompidas antes dela.

2. Dados e preparação

O corpus possui 25 exemplos sintéticos distribuídos em cinco grupos: perguntas frequentes, protocolos, registros e laudos, procedimentos e segurança. Há também quatro protocolos em arquivos Markdown, três pacientes e sete exames em CSV. Os exemplos foram escritos para representar documentos institucionais sem reproduzir informações de pessoas reais.

O script `scripts/prepare_data.py` executa a curadoria. Primeiro, verifica a presença dos campos necessários e a unicidade dos identificadores. Em seguida, aplica padrões de anonimização a instrução, contexto e resposta. O processo interrompe a execução se restar um formato direto de identificação, se houver entradas duplicadas ou se uma resposta for curta demais para o treinamento.

Depois da validação, a preparação cria três conjuntos sem identificadores em comum: treino, validação e teste. O conjunto de treino atualiza o adaptador. O conjunto de validação é usado para escolher a época com menor perda. O conjunto de teste é usado somente após essa escolha, para comparar o modelo base com o adaptador selecionado. A divisão fixa facilita repetir o experimento nas mesmas condições.

A anonimização é limitada: padrões regulares identificam formatos conhecidos, mas não conseguem garantir que toda informação indireta ou todo nome livre tenha sido removido. Como os dados são sintéticos, essa etapa demonstra o mecanismo de controle e não uma certificação de anonimização.

3. Ajuste fino do modelo

O treinamento usa FLAN-T5-small, um modelo de geração de texto formado por codificador e decodificador. A entrada contém uma instrução, uma pergunta e as evidências disponíveis. A saída esperada é o texto de referência associado ao exemplo.

O ajuste é realizado com LoRA. Em vez de alterar todos os pesos do modelo base, LoRA adiciona pequenas matrizes treináveis a projeções do mecanismo de atenção. Essa escolha reduz a quantidade de parâmetros atualizados e torna o treinamento possível em CPU. O programa verifica os tamanhos dos textos antes do treinamento para evitar perda silenciosa de conteúdo por truncamento.

O treinamento executa seis épocas, registra as perdas de treino e validação e salva o melhor adaptador em `models/clinical-t5-lora`. Também produz um arquivo de resultados contendo versões das bibliotecas, identificadores das partições, comparações entre respostas e métricas

descritivas. Esses resultados são locais e devem ser regenerados a cada execução.

Uma redução de perda não significa que a resposta seja clinicamente adequada. A avaliação qualitativa observa se o modelo repete o prompt, mistura idiomas, omite limites ou produz conteúdo sem apoio no contexto. Essas verificações são mais importantes que uma métrica isolada para decidir se uma saída deve ser retida.


4. Assistente com contexto atualizado

O módulo `data_access.py` acessa o SQLite com consultas parametrizadas e apenas de leitura. Para um identificador de paciente válido, ele reúne condições, alergias, exames pendentes e resultados existentes. A aplicação lê a base em cada execução, portanto utiliza o estado atual daquele arquivo local.

O módulo `retrieval.py` carrega os protocolos e cria uma representação TF-IDF. Cada documento recebe pesos para seus termos; palavras frequentes em um único documento tendem a distinguir melhor esse documento do que palavras presentes em todos eles. A similaridade cosseno ordena os protocolos de acordo com as palavras compartilhadas com a pergunta. A aplicação conserva, no máximo, duas fontes acima de um limiar mínimo e registra código, título, versão e caminho relativo de cada uma.

O LangChain une pergunta, dados do paciente e trechos recuperados em um único prompt. O mesmo contrato textual é utilizado na preparação do treinamento e na inferência. A LLM não gera comandos SQL nem escolhe sozinha quais dados escrever no banco.

5. Fluxo LangGraph e controles



O grafo começa anonimizando a pergunta e procurando sinais textuais críticos. Quando há sinal crítico, o fluxo emite um alerta local e termina antes de carregar o modelo. Quando a pergunta solicita diagnóstico, prescrição, dose ou alteração terapêutica, a aplicação recusa a solicitação por

código e também encerra o fluxo.

Nas demais situações, o grafo consulta o paciente e procura protocolos. Sem paciente ou fontes, a geração não ocorre. Com contexto suficiente, o LangChain chama a LLM e o resultado é tratado como rascunho. A etapa final só aceita um trecho que tenha correspondência literal com as evidências e que não contenha padrões de intervenção. Caso contrário, a resposta é retida.

Essa regra é deliberadamente conservadora. Ela reduz o risco de disponibilizar texto inventado, mas pode reter respostas adequadas escritas com outras palavras. Uma coincidência literal também não comprova que o conteúdo seja apropriado ao caso. Por isso toda saída reforça a necessidade de revisão profissional.

Cada chamada gera um registro de auditoria com identificador da execução, duração, etapas concluídas, rota tomada, fontes e eventuais erros. Perguntas, rascunhos e respostas em texto livre não são gravados no log. O registro favorece o rastreamento do funcionamento, mas não substitui controles de acesso, autenticação ou governança de dados.

6. Avaliação

A avaliação separa três aspectos: o comportamento do modelo base e do adaptador, a qualidade textual dos rascunhos e o funcionamento das regras do sistema. As comparações de respostas mostram se o treinamento alterou o comportamento gerativo; elas não constituem validação clínica.

Os testes automatizados verificam a separação das partições, a permanência do modelo de receita no treino, a leitura parametrizada do banco, a recuperação de protocolos, a interrupção de alertas antes da LLM, a recusa de solicitações impróprias, o bloqueio por falta de contexto e o registro de falhas na auditoria.

O script `scripts/evaluate_system.py` executa casos integrados: uma pergunta contextualizada, um alerta, uma recusa, um assunto sem fonte e um paciente inexistente. A avaliação registra as rotas tomadas e permite conferir que alerta e recusa não dependem da resposta gerada pelo modelo.

7. Limitações e conclusão

O projeto é um experimento técnico com corpus reduzido e sintético. Ele não foi avaliado por especialistas, não mede desempenho em uso real e não deve ser aplicado ao cuidado de pacientes. A recuperação lexical não compreende sinônimos com segurança, e a LLM pode produzir texto inadequado mesmo quando recebe contexto.

Apesar dessas limitações, a implementação demonstra um processo completo: preparação e curadoria de dados, ajuste fino local, consulta estruturada, recuperação de fontes, geração contextualizada, fluxo de segurança, rastreabilidade e testes. A retenção de respostas sem suporte e a separação entre geração e decisão clínica são elementos centrais do desenho do protótipo.